

Analiza porównawcza metod nienadzorowanego wykrywania oszustw z kartami kredytowymi

Szymon Oleszek, Maciej Oldakowski, and Paweł Ostrowski

Politechnika Lubelska

Abstract. Duże oraz niezbalansowane zbiory danych wymagają dużej mocy obliczeniowej, czasu oraz dostępu do etykietowanych zbiorów. W przypadku transakcji bankowych dochodzą jeszcze kwestie prywatności danych oraz brak balansu oszustw do realnych transakcji w zbiorze danych. W tym badaniu przedstawiamy podejście nauki oraz wykrywania poprzez model sztucznej inteligencji, która korzysta z etykiet wygenerowanych przez Shapley Additive exPlantations (SHAP) w celu wyłonienia najważniejszych etykiet z autoenkoderem do wygenerowania etykiet w celu wykrywania nieprawidłowości w transakcjach. Wykorzystując publiczny dataset utworzyliśmy zbiory danych o różnych wielkościach, ze względu na ilość etykiet, wygenerowaliśmy dla nich etykiety i obliczyliśmy ich precyzję oraz trafność za pomocą Area Under the Precision-Recall Curve (AUPRC). Wyniki analizy ukazały, że wykorzystanie etykiet z SHAP pozwala na osiągnięcie znacznie lepszych wyników niż nauka na całym zbiorze danych poprzez model Isolation Forest (IF), którego użyto jako model porównawczy. Pokazuje nam to, że do dużych, niezbalansowanych zbiorów, generowanie etykiet poprzez SHAP zwiększa jakość etykiet do wykrywania oszustw. Takie podejście pozwala na dokładniejsze wykrywanie potencjalnych oszustw w dużych niezbalansowanych zbiorach danych transakcji bankowych.

Keywords: SHAP · Wykrywanie oszustw transakcji bankowych · Uczenie nienadzorowane · Uczenie nadzorowane

1 Wprowadzenie

1.1 A Subsection Sample

Please note that the first paragraph of a section or subsection is not indented. The first paragraph that follows a table, figure, equation etc. does not need an indent, either.

Subsequent paragraphs, however, are indented.

Sample Heading (Third Level) Only two levels of headings should be numbered. Lower level headings remain unnumbered; they are formatted as run-in headings.

Sample Heading (Fourth Level) The contribution should contain no more than four levels of headings. Table ?? gives a summary of all heading levels.

2 Metodologia

2.1

3 Analiza wyników

4 Dyskusja

References

1. Kennedy, R.K.L., Villanustre, F., Khoshgoftaar, T.M.: Unsupervised feature selection and class labeling for credit card fraud. *Journal of Big Data* **12**, 111 (2025). <https://doi.org/10.1186/s40537-025-01154-1>
2. Wyjaśnienie terminu AUPRC, <https://glassboxmedicine.com/2019/03/02/measuring-performance-auprc/>. Stan na 04.06.2026
3. Dokumentacja algorytmu Shapley Additive Explanations - SHAP, <https://shap.readthedocs.io/en/latest/>. Stan na 04.06.2026
4. Isolation Forest - Wikipedia, https://en.wikipedia.org/wiki/Isolation_forest. Stan na 04.06.2026
5. Co to jest regresja liniowa?, <https://www.ibm.com/think/topics/linear-regression>. Stan na 04.06.2026
6. Co to jest las losowy?, <https://www.ibm.com/think/topics/random-forest>. Stan na 04.06.2026
7. Zbiór danych, <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>. Stan na 04.06.2026
8. Dokumentacja biblioteki keras, <https://keras.io>. Stan na 04.06.2026