

Analiza porównawcza metod nienadzorowanego wykrywania oszustw z kartami kredytowymi

Szymon Oleszek, Maciej Oldakowski, and Paweł Ostrowski

Politechnika Lubelska

Streszczenie Duże oraz niezbalansowane zbiory danych wymagają dużej mocy obliczeniowej, czasu oraz dostępu do etykietowanych zbiorów. W przypadku transakcji bankowych dochodzą jeszcze kwestie prywatności danych oraz brak balansu oszustw do realnych transakcji w zbiorze danych. W tym badaniu przedstawiamy podejście nauki oraz wykrywania poprzez model sztucznej inteligencji, która korzysta z etykiet wygenerowanych przez Shapley Additive exPlantations (SHAP) w celu wyłonienia najważniejszych etykiet z autoenkoderem do wygenerowania etykiet w celu wykrywania nieprawidłowości w transakcjach. Wykorzystując publiczny dataset utworzyliśmy zbiory danych o różnych wielkościach, ze względu na ilość etykiet, wygenerowaliśmy dla nich etykiety i obliczyliśmy ich precyzję oraz trafność za pomocą Area Under the Precision-Recall Curve (AUPRC). Wyniki analizy ukazały, że wykorzystanie etykiet z SHAP pozwala na osiągnięcie znacznie lepszych wyników niż nauka na całym zbiorze danych poprzez model Isolation Forest (IF), którego użyto jako model porównawczy. Pokazuje nam to, że do dużych, niezbalansowanych zbiorów, generowanie etykiet poprzez SHAP zwiększa jakość etykiet do wykrywania oszustw. Takie podejście pozwala na dokładniejsze wykrywanie potencjalnych oszustw w dużych niezbalansowanych zbiorach danych transakcji bankowych.

Keywords: SHAP · Wykrywanie oszustw transakcji bankowych · Uczenie nienadzorowane · Uczenie nadzorowane

1 Wprowadzenie

Pozyskiwanie wysokiej jakości etykiet do klasyfikacji jest kluczowym zadaniem dla uczenia maszynowego. Proces etykietowania często bywa kosztownym, czasochłonnym i podatnym na błędy przedsięwzięciem. Jakość etykiet to ważny czynnik wpływający na wydajność modeli uczenia maszynowego, a nieodpowiednie etykiety mogą prowadzić do słabych wyników. Co więcej, znaczna część nowo tworzonych zbiorów danych jest domyślnie pozbawiona etykiet. Ta obfitość nieoznakowanych danych stanowi zarówno szansę, jak i wyzwanie dla uczenia maszynowego. Chociaż modele uczenia maszynowego często radzą sobie lepiej z większą ilością danych, niedobór etykiet klas w dziedzinach takich jak diagnostyka obrazowa w medycynie czy wykrywanie oszustw znacznie ogranicza użyteczność modeli nadzorowanych, które do działania wymagają etykiet. We

wspomnianych dziedzinach dodatkowym problemem jest też prywatność danych, gdyż etykietowanie często wymaga przyznania ekspertom dostępu do danych, co może być niemożliwe ze względu na przepisy dotyczące prywatności. Kwestie prywatności ograniczają również publiczną dostępność finansowych zbiorów danych, takich jak zbiory transakcji kartami kredytowymi wykorzystywane do wykrywania oszustw. Nienadzorowane i zautomatyzowane podejście może rozwiązać te problemy. Ponieważ interakcja z człowiekiem nie jest wymagana, pozwala to na zachowanie prywatności. Tego typu modele uczą się bezpośrednio z cech zestawu danych, a algorytmiczne etykietowanie łagodzi obawy dotyczące prywatności poprzez wyeliminowanie bezpośredniego zaangażowania człowieka. Jednak, chociaż nienadzorowane modele mogą być użyteczne, często nie osiągają tak dobrych wyników jak modele nadzorowane. Podkreśla to potrzebę postępu w badaniach nad uczeniem maszynowym w celu sprostania wyzwaniom związanym z nieaetykietowanymi danymi i generowaniem wysokiej jakości etykiet.

Selekcja cech to kluczowa technika redukcji danych, która rozwiązuje szereg problemów nieodłącznie związanych z uczeniem maszynowym, zwłaszcza w kontekście dużych i niezbalansowanych danych, co jest wyraźnie widoczne w przypadku danych dotyczących oszustw. Poprzez identyfikację i zachowanie tylko najbardziej istotnych informacji, techniki wyboru cech zmniejszają wymiarowość danych, co z kolei upraszcza model. Uproszczony model zmniejsza koszt obliczeniowy, jest łatwiejszy w interpretacji i często ma wyższą wydajność. Jest to szczególnie ważne w przypadku silnie niezbalansowanych danych. Niezbalansowanie klas, w odniesieniu do problemu klasyfikacji binarnej, występuje wtedy, gdy reprezentacja jednej klasy jest w znacznym stopniu zniekształcona w porównaniu z drugą. Zbiór danych może być uznany za niezbalansowany, jeśli proporcja między klasami przekracza 1:4. Poważne lub wysokie niezbalansowanie występuje, gdy proporcja między klasami maleje i może przekroczyć nawet 1:1000. Problemy wynikające z niezbalansowania klas rosną wraz ze wzrostem tego wskaźnika, co wymaga zastosowania specjalnych rozwiązań dla efektywnego uczenia modelu i jego klasyfikacji. Nasza praca ma na celu wykorzystanie selekcji cech w celu poprawy jakości etykiet generowanych przez istniejącą już metodologię, która została specjalnie zaprojektowana do radzenia sobie z wyzwaniami związanymi z brakiem etykiet i wysokim niezbalansowaniem klas. Realizowane jest to poprzez nienadzorowane generowanie nowych etykiet przy użyciu wyłącznie najważniejszych cech.

Zazwyczaj proces selekcji cech ma charakter nadzorowany. Nasza praca skupia się jednak na nienadzorowanym scenariuszu, stąd potrzebna jest nienadzorowana technika wyboru cech. Algorytm SHapley Additive exPlanations (SHAP) oferuje solidną metodę selekcji cech, dostarczając ranking ich ważności, który może być zastosowany niezależnie od tego, czy dane mają już etykiety, czy nie. W przypadku scenariusza z danymi bez etykiet, na którym skupiamy się w tej pracy, najpierw algorytm nienadzorowany jest trenowany na zbiorze danych, a następnie funkcja SHAP kernel explainer oraz funkcja wartości SHAP są używane do ułożenia cech według ich ważności. Wykorzystując wyniki modelu nienadzorowanego, Isolation Forest, podejście to zapewnia opłacalny sposób na przeprowadzenie

selekcji cech, gdy gotowe etykiety są niedostępne. Aby ocenić, czy dobór cech z pomocą SHAP poprawia jakość wygenerowanych etykiet, zastosowaliśmy to rozwiązanie do powszechnie używanego i publicznie dostępnego zbioru danych Credit Card Fraud Detection, który jest jedynym publicznie dostępnym zestawem rzeczywistych danych tego rodzaju.

Używamy algorytmu SHAP w sposób nienadzorowany, aby przeprowadzić selekcję cech i stworzyć dwa nowe zbiory danych, wykorzystujące wyłącznie podzbiór wszystkich dostępnych atrybutów. Następnie, do każdego ze zbiorów przykładamy nienadzorowaną technikę etykietowania, mierząc jakość uzyskanych rezultatów z wykorzystaniem selekcji cech, jak i bez niej. Zapewniamy empiryczne wyniki mierzące jakość etykiet i porównujemy je z nienadzorowanym modelem bazowym, jakim jest algorytm Isolation Forest (IF).

Wykorzystanie technik uczenia maszynowego do analizowania takich danych jest kluczowe z kilku powodów. Skala oszustw związanych z kartami kredytowymi jest ogromna, co każdego roku generuje globalne straty rzędu miliardów dolarów. Wywiera to znaczną presję finansową na gospodarkę i prowadzi do wzrostu kosztów dla wszystkich użytkowników kart. Postęp w uczeniu maszynowym może pomóc zmniejszyć te straty, umożliwiając szybsze i dokładniejsze wykrywanie przypadków nieuczciwego użycia kart. Ponadto, uczenie maszynowe oferuje korzyści z zakresu szybkości i jest w stanie zidentyfikować wzorce, które można przeoczyć w toku manualnej analizy.

2 Metodologia

2.1

3 Analiza wyników

4 Dyskusja

Literatura

1. Kennedy, R.K.L., Villanustre, F., Khoshgoftaar, T.M.: Unsupervised feature selection and class labeling for credit card fraud. *Journal of Big Data* **12**, 111 (2025). <https://doi.org/10.1186/s40537-025-01154-1>
2. Wyjaśnienie terminu AUPRC, <https://glassboxmedicine.com/2019/03/02/measuring-performance-auprc/>. Stan na 04.06.2026
3. Dokumentacja algorytmu Shapley Additive Explanations - SHAP, <https://shap.readthedocs.io/en/latest/>. Stan na 04.06.2026
4. Isolation Forest - Wikipedia, https://en.wikipedia.org/wiki/Isolation_forest. Stan na 04.06.2026
5. Co to jest regresja liniowa?, <https://www.ibm.com/think/topics/linear-regression>. Stan na 04.06.2026
6. Co to jest las losowy?, <https://www.ibm.com/think/topics/random-forest>. Stan na 04.06.2026
7. Zbiór danych, <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>. Stan na 04.06.2026
8. Dokumentacja biblioteki keras, <https://keras.io>. Stan na 04.06.2026